

认知沉积的可测框架：参照系、度量与效度条件

版本： PACSP-M 1.1.0 **名称：** PACSP-M = *Pairwise Average Cognitive Semantic Proximity — Measurement*（成对平均认知语义接近度的测量框架） **性质：** 一个完整、正面描述的测量框架。不是修订清单，也不以任何先前版本为前提。 **演变来源：** PACSP-ID 7.0.0（见附录 C） **方法定位：** 本文先给出**可靠的部分**，再给出**被实测否决的部分**及否决依据。

〔关于名称〕 M 指 **Measurement**，即“测量框架”。它**不是** "Modified"——PACSP-M **不是** PACSP-ID 的补丁，而是回答一个不同问题的独立工作（见附录 C.1）。名称中的 D（度量）取自 *pairwise average* 的首字母与 *proximity* 的语义。

摘要

本文建立一个测量认知沉积的框架，其构造原则有两条：

P1（可追溯性）： 任何被报告的量，其数值必须能追溯到一组**已声明**的选择，并且该量对**未声明**的选择不敏感。 **P1'（敏感性）：** 该量必须对它**声称要测量**的差异敏感。

两条必须同时满足。 只满足 P1 的量是“不变但无信息”（实测反例见 §2.4）；只满足 P1' 的量是“敏感但不可复现”（C_T，见 §3.3）。

这两条淘汰了本文检验过的**四种**候选表示中的三种，并改变了第四种的解释。

框架的构造：

1. **参照系** (Ω, d, M)——嵌入空间、度量与其标定参数 M 。

M **必须声明**，因为实测：仅更换生成模型，同一批语料的核心量相差 **31%**。

2. **表示**——每个快照一个向量 $v_k \in \Omega$ ；语料是一个集合 $\{v_1..v_n\}$ ，

不是一个序列。这一选择是被强制的：把语料视为序列会使核心量产生 **20–51%** 的顺序依赖（§3.3）。

3. **核心度量**——全部成对距离的均值：

$$D = (1) / (C(n, 2)) \sum_{\{i < j\}} \|v_i - v_j\|_2$$

零参数（相对于给定 Ω ）、顺序无关、不需要语言模型。

4. **不确定度**——自助法区间。实测： D 的估计精度为 **1–8%**（CV 0.012–0.081），

而带参数的替代表示达 **51–191%**。

5. **报告规范**——区间、参数扫描、零模型对照、与最简基线比较、独立路径复核（§6）。

框架给出的实证结果：

在五个**同域**人机配对上，人类臂的 D **全部更低**：比值 0.8305 / 0.8691 / 0.9205 / 0.9147 / 0.9358，**跨度仅 1.13 倍**，5/5 区间排除 1。

长度控制：lyrics 与 techdoc 的长度并不匹配（11.64× 与 7.92×）。把每条文本裁剪到共同长度后，**方向一致不变、无任何配对翻转、最大偏移 6.9%**；且长度比与 D 比值几乎不相关。**长度不是驱动因素**（§4.4）。

一处被推翻的例外：早期版本报告技术文档域方向相反（比值 1.4426），并将假设 H1（体裁效应）列为待检验。**问题重测后反转消失**——该配对比较的其实是**主题差异**（人类臂「自注意力信用」vs 机器臂「Python 环境」），不是人机差异。**H1 据此不成立**（§4.5）。

最重要的限定：参照系敏感性（§4.9）。D 的判别力**依赖编码器**。三个编码器实测：

编码器	维度	家族	方向一致	跨度
bge-large-zh-v1.5	1024	bge	5/5	1.13×
bge-small-zh-v1.5	512	bge	5/5	1.12×
text2vec-base-chinese	768	其他	3/5	1.22×

参数缩小 14 倍（326M → 24M）结论不变；换家族后部分失效。跨家族的平均绝对差是同家族的 **1.88 倍**。但失效的性质是**"效应量收缩"而非"方向反转"**——text2vec 的两处不一致仅 1.0100 与 1.0048，即比 1 高 1.0% 与 0.5%。

所以 **‘D’“零参数”只在相对于给定 ‘Ω’ 的意义上成立**；编码器本身是必须声明的参数。**框架要求在 ≥2 个编码器上复核，并把结果一并报告**（§4.9）。

框架明确不主张的：D 给出的是**统计可分性**，不是**生成机制的判定**（§7.3）；也不是**"认知沉积量"本身**（§7.1）。

框架放弃了什么： $C_T = \sum \mu_k \delta_k$ 作为**"沉积总量"**的解释（§5.1）；核嵌入作为**"无损表示"**的主张（§5.2）；**匹配矩阵图的层级**（§5.3）；**残差修正**（§5.4）。各自的复活条件见 §5.5。

落点：本文全部度量——包括最稳健的 D——测量的是**文本在嵌入空间中的分布形态**。分布形态是生成的**产物**，不是生成的**过程**。因此它们原则上不能回答**"认知沉积是什么"**，只能回答**"在给定的参照系中，两组文本的语义分布是否可区分"**（§8.1）。

关键词：认知沉积、测量效度、参照系、顺序无关、零参数基线、统计可分性

1. 框架的构造原则

1.1 两条原则

P1（可追溯性）：任何被报告的量，其数值必须能追溯到一组**已声明**的选择，并且该量对**未声明**的选择不敏感。

P1'（敏感性）：该量必须对它**声称要测量的**差异敏感。

P1 与 P1' 必须同时满足。

只满足	后果	本文中的实例
仅 P1	不变但无信息	σ 路线 D：对 σ 不敏感（CV 0.0026），却 0/5 区间排除 1（§2.4）
仅 P1'	敏感但不可复现	C_T：能区分语料，但 20–51% 由文件顺序决定（§3.3）

这就是为什么两条必须并列。 单独任何一条都可以被一个退化的量满足：常数满足 P1，随机数满足 P1'。

为什么是这一条：本文检验的三种替代表示都以同一方式失败——它们各自消除了一项敏感性，却引入了一个**未声明且影响力更大的新参数**。

表示	消除	引入	新参数的影响
核嵌入 (Φ, Ψ)	顺序敏感	核尺度 σ	$\sigma \times 1.6 \rightarrow$ 未归一化比较变化 70–133%
匹配矩阵图 $C=Y^T Y$	顺序 + σ	情绪词表、探测短语	换短语 $\rightarrow$ 结果 跨 826 倍并反转
残差修正	—	—	反而 破坏方向一致性

P1 + P1' 是这些失败的直接推论。 它们不要求度量“没有参数”，而要求**参数被声明、对未声明者不敏感、对目标差异敏感**。

§6.3 的两条操作判据是这两条原则的直接推论，不是独立技巧：

原则	判据
P1	自助法 $CV > 0.15 \rightarrow$ 不应比较（估计不精确）
P1'	区间必须排除 1（效应可分辨）

1.2 一条推论

P2（可分性 $\neq$ 机制）：统计上能把两组分开，**不等于**指出了分开的机制。

本文全部检验中，**混淆这两个命题是最常见的错误**。D 在五个域中四个把人类与机器分开，但**为什么分开**尚未定位（§7.3）。

P2 排除了若干过度解读，包括作者自己在整理过程中犯过的两次（§3.4、§7.3）。

2. 参照系

2.1 定义

框架的参照系是一个三元组：

$$\Omega = (X, d, M)$$

- X: **嵌入空间**, $\dim X = d$ (本文 $d = 1024$, BAAI/bge-large-zh-v1.5)
- $d(\cdot, \cdot)$: **度量** (本文为欧氏距离)
- M: **标定与生成参数**, 包含嵌入模型标识、版本、以及任何影响向量的处理

2.2 为什么 M 必须显式声明

实测依据：同一题、同一提示、同一指令，**仅更换生成模型**（各 31 篇）：

```
qwen2.5:7b          C_T = 9.5902 Se
deepseek-r1:14b     C_T = 6.6421 Se      相差 31%
```

同一批文本换成不同嵌入空间时，比值在 **1.43–1.51** 之间（PACSP-ID §10.6 已记录）。

参照系不是"先于一切"的抽象空间，而是一个具体的、带参数的选择。 它必须被声明；声称它是"泛"的反而是把未声明参数藏进符号里。

2.3 Ω 是固定的，但不是任意的

框架要求：**在同一个报告内部，` $\Omega$ ` 固定不变。** 跨报告的数值只有在 Ω 相同时才可直接比较。

〔为何不要求"绝对固定"〕若要求 Ω 对所有研究相同，就必须有一个 "正确的"嵌入空间——本文没有找到，也不预期存在。

2.4 σ 类参数：四条解决路线的实测

核嵌入引入尺度参数 σ 。**对 RBF 核，改变 ` $\sigma$ ` 使 ` $\Phi$ ` 在每一点乘一个与 ` $x$ ` 无关的正数：**

$$K(x,v;\sigma) = \varphi(v)^{\{\sigma_0^2/\sigma^2\}}, \varphi(v) = \exp\{-d^2/2\sigma_0^2\} > 0$$

因此 ` $\Phi_\sigma = c(\sigma) \cdot \Phi_{\{\sigma_0\}}$ `，而任何"先在自变量上归一化"的泛函对 ` $\sigma$ ` 精确不变。

〔一处需要标注的数字〕先前实测的「 $\sigma \times 1.6 \rightarrow \Phi$ 变化 **70–133%**」（poem 0.70、lyrics 0.77、techdoc 1.16）测的是"在 L_2 范数下比较未归一化 ` Φ ""的敏感性，**不是表示本身的敏感性**——常数 c 在 L_2 比较中不抵消，被计入了。该数字**仍然有效**，但应标注为"未归一化 L_2 比较"的敏感度。

四条解决路线及其代价

路线	做法	$\sigma \times 1.6$ 变化 (均值)	判别力 (方向一致 / 跨度)
A 重心	Φ 归一化为概率向量后比较	0.3682	0/5 / 1.67×
B 对 σ 积分	在 $\sigma_0 \times \{0.5, 0.7, 1.0, 1.4, 2.0\}$	0.0808	0/5 / 2.06×

	上平均，不选单一值		
C Laplacian 核	用 $\exp(-d/\sigma)$ 替代高斯核	0.1928	1/5 / 3.08×
D 形状统计	只比较剖面的熵与集中度	0.0070	5/5 但 0/5 可分辨

四条路线全部消除 σ 敏感与顺序敏感，代价是全部丧失判别力。

D 是必须记录的反例：它给出 5/5 方向一致、跨度仅 1.01×，看起来最好。但按篇目自助法，5/5 区间全部跨过 1 (0/5 排除 1)，自助法 CV 仅 0.0026–0.0043。

效应只有 1%，噪声不足以翻转它的符号，所以它看起来"5/5 一致"；但 1% 的效应本身与 0 不可分辨。"方向一致"与"可分辨"是两个不同的判据。D 满足前者，不满足后者。

一条普遍教训

对干扰参数不变 $\neq$ 对信号敏感。使一个量对 σ 不变的操作（归一化），同时使它对该量本要捕捉的差异不变。

A/B/C 是这条的实例；D 是它的极端形式——把剖面压缩成几个形状量之后，所有语料的剖面形状几乎相同（比值 0.988–0.999），"不变"到了无信息。

这补足了 P1：只要求"对未声明参数不敏感"不够，还必须要求"对要测的差异敏感"——后者由 §4.6 的正面比较承担。

操作结论

若确实需要核嵌入：用路线 B（对 σ 积分），并把 σ 说明为"已被积分掉"，而不是"选了一个值"。

但若目的是判别：不要使用核嵌入的任何变体。四条路线在此用途上均无效。

对本框架而言，这个问题不需要回答——换用不含 σ 的 D 即可 (§4)。

3. 表示：语料是集合，不是序列

3.1 选择

$$\text{语料} \leadsto \{v_1, v_2, \dots, v_n\}, v_k \in X$$

集合是无序的。这不是审美选择，而是被实测强制的。

3.2 一个替代选择：序列

若把语料视为序列 $\gamma: [0, n] \rightarrow X$ ，核心量就变成沿路径的累加。本文检验的最强形式是 PACSP-ID 的 $C_T = \sum_k \mu_k \delta_k$ 。

3.3 为什么集合表示被强制

对同一批文本只打乱读取顺序，200 次随机排列：

语料	按文件顺序	打乱均值	偏差	在打乱分布中的百分位
poem	1.8950	2.7812	-31.9%	0.0%
lyrics	2.1261	4.3766	-51.4%	0.0%
techdoc	7.3982	9.2429	-20.0%	0.0%
machine_poem	3.8271	4.2686	-10.3%	0.0%
hc3_human_medicine	14.9678	15.0413	-0.5%	43.0%
hc3_ai_medicine	19.3988	19.5930	-1.0%	28.5%

打乱内部的变异很小（CV 0.016–0.048），但按文件顺序的值落在或低于全部 200 次排列（百分位 0.0%）——这是系统性效应，不是噪声。

解读：poem、lyrics、techdoc 的原始编排使相邻篇目语义更接近，故位移更小；打乱后相邻随机，位移增大。HC3 语料的文件顺序本身任意，故打乱不变（百分位 28.5–43.0%）。

序列表示下，20–51% 的数值由"文件怎么排"决定，而不是由"内容是什么"决定。

3.4 顺序敏感是不可修复的（一项否定结果）

我曾假设这是实现的局部化缺陷，并测试了五种 μ 的局部化程度（as-filed 值与 200 次置换均值的偏差）：

μ 变体	定义	平均 \	偏差\		平均 CV
global	集合级统计量，对全部 k 相同	0.1413	0.0208		
window	PACSP-ID 现行实现，半径 5	0.1915	0.0303		
narrow	半径 1	0.2457	0.0445		
adjacent	$1 - \cos(v_{\{k-1\}}, v_{\{k+1\}})$ ，严格局部	0.2185	0.0416		
none	$\mu \equiv 1$ ，退化为总路径长度	0.1402	0.0220		

三项判定：

- 6. `global` (0.1413) 优于现行实现 (0.1915) ——把集合级量当局部权重用，确实扭曲了离散化。PACSP-ID §3.5 的"连续部分由相邻距离计算"因此不成立。
- 7. 局部化使情况变差：narrow 0.2457、adjacent 0.2185，都高于现行实现。
- 8. ` $\mu \equiv 1$ ` 最好 (0.1402) 。

顺序敏感是"沿序列求和"这一步的内禀性质。一个随位置变化的逐项权重只会加剧它，不会消除它。要消除它必须放弃求和——那时它就不再是同一类量。

这是框架选择集合表示的直接理由，也是本框架放弃 `C\_T` 作为"沉积总量"的理由。

4. 核心度量

4.1 定义

$$D(\{v_k\}) = (1) / (C(n, 2)) \sum_{\{i < j\}} \| v_i - v_j \|_2$$

全部成对嵌入距离的均值。

4.2 性质

性质	状态	依据
顺序无关	✔ 构造保证	对集合的对称函数
额外参数	✔ 无——但仅相对于给定参照系 `Ω`	§4.9
需要语言模型	✔ 不需要	仅需嵌入
计算成本	✔ $O(n^2)$ 距离, $O(n)$ 次编码	—
估计精度	✔ 1–8% (CV 0.012–0.081)	§4.3
判别力的跨模型稳定性	⚠ 同家族稳定, 跨家族减弱	§4.9

〔关于"零参数"的精确含义〕D 除参照系 Ω 外没有参数：没有窗口、没有核尺度、没有词表、没有探测短语。但 `Ω` 中的编码器本身是一个必须被声明的选择——D 的判别力依赖它 (§4.9)。这一区分在 §4.9 展开。

4.3 实证：五个同域人机配对

域	人类	机器	比值	95% CI	排除 1	自助法 cv (人/机)
poem	0.5434	0.6543	0.8305	[0.6842, 0.9742]	✔	0.0805 / 0.0237
lyrics	0.6365	0.7324	0.8691	[0.7482, 0.9812]	✔	0.0626 / 0.0269
techdoc	0.8422	0.9149	0.9205	—	—	—
medicine	0.9982	1.0913	0.9147	[0.8875, 0.9413]	✔	0.0151 / 0.0154
openqa	1.1187	1.1954	0.9358	[0.9174, 0.9525]	✔	0.0134 / 0.0124

5/5 区间排除 1。

跨度：0.8305 → 0.9358，即 1.13 倍，五个域方向一致。

〔修正记录〕早期版本此处报告两个跨度（1.13 倍与含 techdoc 的 1.74 倍），因为当时认为技术文档域方向相反。§4.5 表明那是误设配对的产物，反转已消失，所以现在只有一个跨度。保留这段说明，是因为"报告两个跨度"当时是正确做法—— 错误不在报告方式，而在配对本身。

4.4 长度控制：一项可能推翻本节结果的检验

§4.3 的五个配对只是"同域"，不是"同长度"。实测长度：

配对	人类字节均值	机器字节均值	长度比
poem	110	97	1.13×
lyrics	1,160	100	11.64×
techdoc	18,329	2,314	7.92×
medicine	428	424	1.01×
openqa	388	414	0.94×

`lyrics` 与 `techdoc` 严重不匹配。若 D 受长度驱动，§4.3 就是长度效应。

控制实验：把每条文本裁剪到两臂中位数较小者（target），再算 D。

配对	裁剪目标（字符）	原比值	裁剪后比值	变化
poem	40	0.8305	0.7804	0.940
lyrics	40	0.8691	0.9292	1.069
techdoc	1,232	1.4426	1.4437	1.001
medicine	141	0.9147	0.9065	0.991
openqa	139	0.9358	0.9337	0.998

方向一致： 原始 4/5 → 裁剪后 4/5
方向翻转： 无
最大相对偏移：6.9%

另一项更强的证据：长度比与 D 比值几乎不相关—— lyrics 长度比 11.64 而比值 0.87，techdoc 长度比 7.92 而比值 1.44。

结论：长度不是 `D` 的驱动因素。§4.3 的结果在长度受控后保持。

〔限制〕裁剪是侵入性的：lyrics 的目标只有 40 字符（原均 411），意味着裁剪后的比较不再是对完整文本的比较。所以这项控制排除了"长度主导"，但不等于"长度完全无影响"—— 最严格的做法是采集同长度语料，本文未做。

4.5 一次被推翻的例外：techdoc 的"反向域"

本节记录一处修正。早期版本报告技术文档域方向相反（比值 1.4426，区间 [1.3043, 1.5903]），并将其列为"必须报告的例外"。后续审计发现该配对是误设的；修正后反转消失。

误设之处

项	人类臂 techdoc	机器臂 machine_techdoc
主题	「自注意力信用 / 数字货币」	「Python 虚拟环境」

均字节	19,545	2,350 (7.92×)

两臂既不同题，也不同长。所以那个比值比较的是**主题差异**，不是人机差异。

同题重测

从每篇人类文本取首句作为主题，用同一模型（qwen2.5:7b）在同题上生成 31 篇技术说明文：

配对	人类 D	机器 D	比值
原配对（不同主题）	0.8422	0.5838	1.4426
同题配对（新建）	0.8422	0.9149	0.9205
同题 + 长度控制（截至 1,476 字符）	0.8426	0.9149	0.9210

反转消失。 0.9205 落在其余四域的同向区间（0.83–0.94）内。

〔长度控制〕裁剪到共同中位长度后，比值从 0.9205 变到 0.9210，**变化 0.1%**。所以这也不是长度效应。

〔生成质量核查〕31 篇生成文档为 933–2,496 字符，**无一篇是会话式回应**。（早期我曾据生成脚本的进度输出误判为“有会话回应”，**实为脚本打印的是题面而非正文**——一处我自己的误读，记录以免重犯。）

修正后的判读

在五个域中，人类臂的 `D` 全部更低。 原本报告的“反向域”是**误设配对的产物**，不是体裁效应。

跨度为 0.8305 – 0.9358，即 1.13 倍，五个域方向一致。

〔据此否定假设 H1〕H1 曾提出“技术文档域的人类写作本身更发散，AI 更模板化”。**该假设在本检验中不成立。**

修正后的完整数据

域	人类 D	机器 D	比值
poem	0.5434	0.6543	0.8305
lyrics	0.6365	0.7324	0.8691
techdoc（同题）	0.8422	0.9149	0.9205
medicine	0.9982	1.0913	0.9147
openqa	1.1187	1.1954	0.9358

〔一项提示——**已被检验并否定，见 §4.5 末与 §4.7**〕机器臂一列看起来比人类臂更集中（0.65–1.20，跨 1.83× vs 0.54–1.12，跨 2.06×），曾据此疑“机器文本更同质”。**单篇层面的检验否定了它，且方向相反。保留此段是为了记录：臂级跨度的比较会给出误导信号。**

〔对 PACSP-ID 的含义〕其 §10.2 的"三域对比"含 techdoc，而该域的正确配对（问题）尚未在其数据中建立。所以其"域间差异大于轴间差异"的结论不能据此域支撑。

一项被检验并否定的初步观察

§4.5 曾记录一个提示：机器臂一列的 D 跨度 (1.83×) 窄于人类臂 (2.06×)，疑"机器文本更同质"。该提示经检验不成立。

检验设计：臂级只有 5 vs 5，样本太少，所以降到单篇层面——每篇文本计算两个只在自身语料内定义的量：

量	定义
质心距离	$\ v - \text{mean}(\text{同语料向量})\ $ ，该篇离自身群体的中心多远
近邻距离	该篇到同语料其余篇的平均距离

把每个域先除以自身均值（消除域级尺度），再合并：155 vs 155 篇。

结果（自助法 2000 次，五个截断预算）：

预算	质心均值比	质心标准差比	近邻均值比	近邻标准差比
36	1.0000	3.2374	0.9999	4.6644
80	1.0006	2.8158	1.0000	3.5589
150	0.9996	2.4413	0.9999	2.8150
300	0.9996	2.2013	0.9999	2.4168
600	1.0003	2.2315	0.9999	2.4254

均值比排除 1 的预算： 0/5 ← 平均紧凑度无差别
标准差比排除 1 的预算： 5/5 ← 离散度有差别，机器更大

三项判定：

9. 均值比全部约等于 1（区间含 1）——机器文本的平均紧凑度与人类无差别。

10. 标准差比远超 1 (2.2–4.7) ——但方向与提示相反：

机器文本的离散度更大，不是更小。

11. 结论对截断预算稳健（五个预算下方向一致）。

更准确的图景：

层面	人类	机器
整臂 `D`（群体内聚度）	更低 (5/5 域)	更高
单篇离质心的距离（平均）	相同	相同
单篇距离的离散度	更小	更大

即：人类臂里的篇目彼此更相似，且相似程度更均匀；机器臂的平均相似度与人类相同，但内部差异更大。
"机器更模板化"的直觉在本文数据上不成立。机器文本并非更整齐地挤在一起，而是摊得更开、但同样地远离中心。

〔为何原提示误导〕原观察比较的是两个臂级 `D` 值的跨度，那是 5 个域 × 2 组 = 10 个点的范围，容易受域组成影响。降到单篇层面后信号方向反转——这是"样本层级选错会翻转结论"的一个实例。

〔对 §7.1 的含义〕原提示若成立，D 的人机判别就可能是"模板化判别"。检验后该顾虑被排除（至少在本文五个域上）：D 的差异不是来自机器文本更整齐。

4.6 与替代表示的正面比较

同一批语料上的配对比值（人类 ÷ 机器）：

域	D (本文)	node_volume (匹配矩阵图)
poem	0.8305	0.3264
lyrics	0.8691	0.0579
medicine	0.9147	0.1940
openqa	0.9358	0.6340
方向一致	✓ 4/4	✓ 4/4
跨度	1.13×	10.95×

两者在"方向一致性"上打平。差别在幅度。

推论：既然两者方向都对，node_volume 多出的 10 倍变动主要来自域，而非人机判别。更大的跨域方差是噪声，不是判别力。

区间：

度量	区间排除 1	逐篇/自助法 cv
`D`	5/5	0.012 – 0.081
node_volume	3/5	0.51 – 1.91 (约 37 倍)

依赖成本：

	D	node_volume
语言模型	✗	✓ 7B
情绪词表	✗	✓ 95 词，敏感
阈值	✗	✓ 需固定
探测短语	✗	✓ 敏感 826 倍
GPU	✗	✓ 需 4-bit 量化

4.7 一个教训：配对必须同题

§4.5 的修正是本文方法论上最值得记录的一处，因为它**不是度量的问题，是配对的问题**。

正确的配对条件（按重要性排序）：

#	条件	本文的实测
1	同主题	违反时比值从 0.9205 变成 1.4426（ 偏离 57% ）
2	同体裁	已满足（五个域各自内部同体裁）
3	长度相近	违反时最大偏移 6.9%（§4.4）
4	同采集方式	HC3 两臂同源；poem/lyrics/techdoc 的两臂不同源—— 这是遗留缺陷

主题不匹配的代价（57%）远大于长度不匹配（6.9%）。这与直觉相反：长度是显见的混淆，主题是隐性的，而后者影响更大。

为何这条容易漏掉：本文的五个配对都“同域”，看起来已受控。但“技术文档”是一个**域**，不是**主题**——人类臂写数字货币，机器臂写 Python 环境，**两者同域而不同题**。

对报告规范的含义：§6 的五条检验应补一条——**报告配对的主题来源，并在主题不匹配时明确标注**。

一个已被排除的顾虑

原提示（机器臂的 D 跨度更窄，疑“机器更同质”）**经单篇层面检验后不成立，且方向相反**——机器文本的离散度更大，不是更小（§4.5 末）。

这排除了一个对 §7.1 的直接威胁：若机器文本果真更整齐，则 D 的人机判别就可能是“模板化判别”。**检验表明 `D` 的差异不是来自机器文本更整齐**。

〔但仍未回答〕D 的差异**究竟来自什么**，本文没有定位。统计可分性成立，机制仍未知（§7.3）。

4.9 参照系敏感性：编码器本身是一个必须声明的参数

这是本文对 `D` 最重要的限定。前面反复说 D“零参数”——那只在**给定参照系 `Ω`** 的意义上成立。**编码器本身就是 `Ω` 里的一个参数**，而 D 的判别力依赖它。

检验

三个不同规模、不同家族的编码器，同一批语料：

编码器	维度	家族	方向一致	跨度
bge-large-zh-v1.5	1024	bge	5/5	1.13×
bge-small-zh-v1.5	512	bge	5/5	1.12×
text2vec-base-chinese	768	其他	3/5	1.22×

逐域比值：

域	bge-large	bge-small	text2vec
poem	0.8305	0.8728	0.9725
lyrics	0.8691	0.9038	0.8309
techdoc	0.9205	0.8907	1.0100
medicine	0.9147	0.9777	1.0048
openqa	0.9358	0.9562	0.9634

两项判定

① 不是"模型太小"的问题。

把参数从 326M 缩到 24M (14 倍)、维度从 1024 降到 512，结论完全不变 (5/5，跨度 1.13 → 1.12)。

② 是"模型家族"的问题。

对比	平均绝对差
同家族 (bge-large vs bge-small)	0.0380
跨家族 (bge-large vs text2vec)	0.0775
跨家族 (bge-small vs text2vec)	0.0652

$$\text{跨家族} / \text{同家族} = 0.0714 / 0.0380 = 1.88\times$$

但"失效"的性质很重要

text2vec 的两处不一致是 `1.0100` 与 `1.0048`—— 只比 1 高 1.0% 与 0.5%。那不是方向反转，是效应量收缩到 1 附近、变得不可分辨。

编码器	平均 \	比值-1\		最大	最小
bge-large	0.1059	0.1695	0.0642		
bge-small	0.0798	0.1272	0.0223		
text2vec	0.0496	0.1691	0.0048		

text2vec 的全部比值落在 [0.8309, 1.0100]，是三者中最紧的区间，而它的平均偏离只有 bge-large 的一半。

所以准确表述是：在 text2vec 空间中，人机差异总体上更小，两处配对收缩到 1 附近，于是"方向一致"这个判据失去分辨力。

与 §2.4 那个假阳性是同一现象的两面

情形	效应量	方向一致	区间排除 1	判据表现
σ 路线 D	~1%	5/5	0/5	假阳性
text2vec	~1%	3/5	—	判据失效

当效应量接近噪声水平时，"方向一致"与"区间排除 1"都会失去意义。

这是 §6.3 两条判据必须并列的又一个理由：单独任一条在效应量极小时都会给出误导信号。

对框架的含义

说法	是否准确
"D 相对于给定 `Ω` 零参数"	✅ 准确
"D 零参数"（绝对）	❌ 不准确——编码器是隐性参数

并且这一发现触及 P1'：D 在 bge 家族内对它声称测量的差异敏感，在另一家族内则不一定。

所以框架要求：

- 12. 报告编码器标识与版本 (§2.2 已要求，此处给出实证理由)
- 13. 在 ≥ 2 个编码器上复核方向一致性，并把跨编码器的结果一并报告
- 14. 若某编码器上效应量收缩到不可分辨，应如实报告"该参照系下不可判别"，

而不是把它计入方向一致性统计

〔未做的检验〕只用了三个编码器，其中两个同家族。更充分的检验需要更多家族，本文未做。这一限制直接影响 §4.3 结论的强度。

4.10 框架中的位置

D 不是"认知沉积量"的等价物。它是：

给定参照系 `Ω` 与一组文本，它们在语义空间中所占体积的一个零参数摘要。

它可比较、可复现、对未声明参数不敏感 (P1)，在长度受控后保持方向 (§4.4)，对目标差异敏感 (P1')——但仅在 bge 家族内成立 (§4.9)。

它是否对应"认知沉积"是一个进一步的、尚未回答的解释问题 (§7.1)。

4.11 参照系的可复用范围：集合之间的关系

本节回答一个超出本文原先用法的问题：Ω 只能给单个集合一个数，还是能标定多个文本集合之间的关系？

答案：能，而且分三个层次，其中第二、三层比第一层更精确。

三个层次

层次	问题	工具	依赖
一（集合内）	这一组文本有多分散？	D	§4.3
二（集合间-均值）	两组的平均距离是多少？	交叉距离均值 + 区间	§4.11
三（集合间-可分）	两组能否互相区分？	分离度、重叠占比	§4.11

第二、三层的输入是交叉距离矩阵——A 的每篇与 B 的每篇之间的距离，共 $n \times m$ 个（本文 $31 \times 31 = 961$ 个），不先降为标量，所以三层可分别读出。

层次二：交叉均值比 D 更精确

配对	交叉均值	95% CI	区间宽度（相对）
poem	0.7648	[0.7612, 0.7686]	0.97%
lyrics	0.9936	[0.9895, 0.9979]	0.85%
techdoc	0.8987	[0.8900, 0.9076]	1.95%
medicine	1.1020	[1.0953, 1.1086]	1.21%
openqa	1.1918	[1.1854, 1.1981]	1.07%

对比单个 `D` 的区间宽度 (§4.3)：0.86 – 4.63（相对）。

交叉均值比单个 `D` 精确约 1–5 倍，因为它在 961 个距离上平均，而不是在 31 篇文本上平均。这是"参照系可广泛复用"的最有力证据：把它用于集合间关系时，它表现更好。

层次三：两个量，判别力远强于 D

分离度（交叉均值 ÷ 组内合并均值）与重叠占比（落在"合并组内距离 P95"半径内的交叉距离比例）：

配对	分离度	重叠占比
lyrics	1.4516	0.066
poem	1.2773	0.797
medicine	1.0547	0.811
openqa	1.0301	0.854
techdoc	1.0230	0.926

重叠占比的跨度是 0.066 → 0.926，即 14 倍，而 `D` 比值的跨度只有 1.13 倍 (§4.3)。

最重要的一项发现：D 不回答单篇归属

这是本节最实质的结果，也是本文的一处方法学修正。

配对	D 比值	重叠占比	单篇可分吗
poem	0.8305 （最极端）	0.797	✗ 否
lyrics	0.8691	0.066	✓ 是
techdoc	0.9205	0.926	✗ 否
medicine	0.9147	0.811	✗ 否
openqa	0.9358	0.854	✗ 否

`poem` 的 `D` 比值最极端，但它的两组分布大量交错。`lyrics` 的 `D` 比值不是最极端，但两组几乎分离。

`D` 比较的是组均值；重叠占比问的是单篇的归属。这是两个不同的问题。在 5 对中，只有 `lyrics` 一对支持"单篇可归属"。

并且这与表层词汇风格无关：D 比值与"跨集合/集合内 Jaccard 比"的相关是 $r = -0.0143$ (n=5) 。词汇风格是 D 看不见的独立维度，且它自身有结构 (lyrics 风格比 0.0395, openqa 1.1984) 。

对 §7.1 的影响 (有利)

先前担心 (§4.5 末)：若 D 的差异来自"模板化判别"，则它与"认知沉积"的关系更远。

现在的表述更强也更安全：

无论 `D` 的差异来自什么，它都不支持"人类文本与机器文本占据不同区域"这一说法。它只支持"两组均值的顺序稳定"。

这降低了过度解读的风险。

操作判据

- 层次一 (集合内)： D + 区间
- 层次二 (集合间)： 交叉均值 + 区间 + 分离度 + 重叠占比
- 不要用 D 的比值推断单篇可分性

限制

#	限制
1	绝对数值依赖 `Ω` ；跨 Ω 只能比较无量纲比值，且比值本身不稳定 (§4.9)
2	半径阈值是任意的 (本文取合并组内距离 P95) ；换 P90/P99 会改变重叠数值， 未做扫描
3	`techdoc` 用了已废弃的原配对 (§4.5) ；其同题配对的交叉关系未测
4	$r = -0.0143$ 只有 5 个点 ，是提示而非结论
5	风格比只用字符二元组 Jaccard ，最朴素的指标；未与其他风格指标交叉验证
6	961 个交叉距离并不独立 (每篇参与 31 次)。均值本身无偏，但区间衡量的是"换一批语料"的不确定性， 该区间未做块自助法修正

5. 被实测否决的部分

记录否决依据，是因为"什么不行"和"什么行"同等重要—— 下一个人 (或三个月后的作者) 不必重走。

5.1 C_T 作为沉积总量：否决

六项敏感性：

#	因素	实测影响
---	----	------

1	文件排列顺序	20–51% (§3.3)
2	文本长度	δ_k 未归一化累加
3	语域/离群	唐代绝句每首 72 字节 (最短) 却得 $C_T = 11.54$, 高于篇均 19,545 字节的技术文档 (7.40)
4	句法结构	同字数下句数 1.19–1.35×
5	生成模型	31% (§2.2)
6	抽样 (n=31)	poem 的 95% 区间跨 3.54 倍

根因: C_T 把若干"本应固定"的量当作自由参数后求和。

一处必须记录的误读: 第 3 项曾被误读为"人类挣扎更深", 实为文言文离现代中文嵌入质心更远。这是本文全部检验中最直接的效度教训——它说明该度量测的是离参照系中心的距离, 不是"努力程度"。

5.2 核嵌入作为"无损表示": 部分否决

构造: $\Phi(\gamma)(x, t) = K(x, \gamma(t))$, 高斯核。

主张	判定	实测
单射性	✅ 成立	特征核下证明正确
Φ 决定 V	✅ 成立	RBF 拟合, 帧含语料时 31/31 精确还原
图表示消解顺序敏感	✅ 完全成立	kNN 图置换下不变量变化 0.0000; 路径图 0.32–2.40
图表示消解 σ 敏感	❌ 不成立	$\sigma \times 1.6 \rightarrow \Phi$ 变化 0.70 / 0.77 / 1.16
自动还原	⚠️ 仅当 $\gamma(t) \in \Omega$	帧外相对误差 0.5544 / 0.5182 / 0.6536

三处诚实说明:

15. "帧含语料时精确还原"是构造上的必然, 不是发现。

真正的信息在帧外: 相对误差 0.52–0.65, 且离散帧上的 argmax 只能返回帧成员。

16. 我曾推断"RBF 下换 σ 只使 K 乘一个常数, 故归一化差应为零"。

推断错了: 嵌入是 L2 归一化的单位向量, $K'/K = \exp((1 - \cos\theta)(1/\sigma^2 - 1/\sigma'^2))$, 逐项不同。

17. 我曾推断"中心化能降低 σ 敏感"。实测逐项到小数点后四位完全相同——

RBF 只依赖成对距离, 而中心化几乎不改变距离矩阵。

一项补充观察: Φ 能把"原序"与"任意他序"分开, 但分不清"哪一种他序"——按哈希重排 (0.0987–0.4605) 与随机打乱 (0.1003–0.4489) 几乎逐项相等。

5.3 匹配矩阵图 $C = Y^T Y$ ：否决

构造：对每个素材用探测短语取模型对情绪词的 next-token 分布 Y ，构造 $C = Y^T Y$ ，用**非对称条件概率**定向层级。

步骤	判定
c 顺序无关	✅ 构造保证 （置换后 max abs diff $\sim 10^{-19}$ ）
无需核，故无 σ	✅ 成立
非对称规则能定向层级	❌ 化简后 只用边缘和
词表与短语不主导	❌ 决定性主导

化简：条件 $C_{ab}/\Sigma C_{ib} < C_{ab}/\Sigma C_{ai}$ 中 $C_{ab} > 0$ 可约，得 $\Sigma C_{ai} < \Sigma C_{ib}$ ——“**行和 < 列和**”，**完全不涉及联合项 `C\_ab`**。实测三组随机矩阵：原规则与“**仅用边缘和**”**逐条一致**（158/158、158/158、154/154）。

一处过强表述的改正：我曾写“规则检测的是边缘不平衡，不是层级”。改用 **Chung-Lu 零模型**（保留行和、列和、总质量）后：

零模型复现真实图最强 200 条边的 39.6% - 83.4%（均值 65.9%）
但真实图边数在 9 个语料中 8 个多于零模型

准确表述：边缘结构贡献了大部分边，但存在可检测的残差。

阈值扫描： t 从 0.005 到 0.10（**20 倍**），人机比值变动 poem 1.0%、lyrics 13%、medicine 6%、openqa 22%——**阈值不是敏感参数**。（我先前“阈值会主导”的推断**被推翻**。）

词表扫描：仅取正面情绪词时，**四个配对方向全部反转**（0.8120 / 0.3721 / 2.0898 / 4.9410）。

探测短语扫描：

短语	poem	lyrics	medicine	openqa
这段素材的核心情绪是	0.347	0.033	0.056	0.298
这段文字表达的情绪是	0.084	0.038	1.203	2.770
这段素材主要体现什么情绪？答：	0.704	0.025	46.273	18.710
情绪：	0.526	0.208	0.490	0.683

medicine 一列跨 826 倍，方向反转两次。

机理检验：我曾推断“探针在数情绪词”。**被推翻：**

语料	文本中情绪词数	探针总质量
machine_poem	0	38.77 （第二高）
techdoc	314	0.13 （最低）

合并相关仅 **0.112 - 0.294**。

自由生成对照（不给词表）给出**相反结论**：

域	受限读数	自由生成	一致?
poem	0.326	0.870	✓
lyrics	0.058	0.579	✓
medicine	0.194	1.571	✗ 反向
openqa	0.634	1.667	✗ 反向

且答案常是**体裁/功能标签**（建议、指导、信息提供），不是情绪。

在非抒情体裁上，这个"情绪探针"测的是**体裁，不是情绪**。

5.4 残差修正：否决

构造： $G_{\text{residual}} = G_{\text{real}} - G_{\text{null}}$ ，在残差上重算体量。

度量	方向一致	跨度
node_volume (原始)	✓ True	10.96×
edge_volume (原始)	✓ True	10.38×
resid_node	✓ True	6.09×
`resid_edge`	✗ False	6.13×

``resid_edge`` 在 **poem 域反转**为 1.5275（人类反而更高），而原始 `edge_volume` 在该域是 0.3470（方向正确）。

〔机理〕人类文本的 γ 总质量本来就小，零模型期望**相对占比更大**，相减时把差异抵消掉了一部分。**残差是过度修正**。

5.5 复活条件

记录否决是为了避免重走，也是为了指明重走的路。以下条件若被满足，相应方案应被重新考虑——**这不是辩解，是可检验的复活标准**。

被否决者	复活条件	本文的实测障碍
<code>`C_T`</code> 作为沉积总量	证明"沿序列求和"本身有理论依据（如时间不可逆性公理），且 μ 的定义能从第一原理导出	局部化不降低顺序敏感（0.1915 → 0.2457）； $\mu \approx 1$ 反而最好（0.1402）
核嵌入作为无损表示	给出 σ 的 理论值 （从数据自身的特征尺度导出，而非选择），并证明该值下的表示对目标差异敏感	$\sigma \times 1.6$ 时未归一化比较变化 70–133%；四条归一化路线（A/B/C/D） 全部丧失判别力 （0–1/5 或 0/5 可分辨）
匹配矩阵图的层级	找到 不依赖词表与探测短语 的替代探针（如从隐藏状态直接读出，不經由 next-token 分布）	换短语跨 826 倍并反转两次；仅取正面词使四配方向全部反转
残差修正	零模型能保留 更多结构 （保留行和、列和 以及成对边际 ），使残差不再过度抵消	<code>resid_edge</code> 在 poem 域反转为 1.5275，原始值 0.3470

一条共同的判据：任何复活方案必须**同时**通过 P1 与 P1' (§1.1) —— 即对未声明参数不敏感，**且**对目标差异敏感。

〔提示〕上表第二行的障碍特别值得注意：**归一化确实消除了`σ`，但那是通过消除所有差异实现的。**所以"给出 σ 的理论值"比"消除 σ"更有希望。

6. 报告规范

这是框架的**操作部分**，直接来自 P1。

6.1 五条必需检验

#	检验	防止的错误	本文中的实例
1	给点估计配区间	把抽样噪声当真实差异	poem 的 C_T 区间跨 3.54 倍
2	做参数敏感性扫描	把参数效应误认为数据效应	探测短语使结果跨 826 倍
3	与最简基线正面比较	把"问题更少"误认为"信息更多"	node_volume 不如零参数 D
4	做零模型对照	把边缘分布伪迹当结构	零模型复现 39.6–83.4% 的边
5	换一条独立路径复核	把单一方法伪迹当现象	自由生成 vs 受限读数方向相反

6.2 报告模板

参照系 : 嵌入模型 + 版本 + 维度 d
处理 : 长度控制方式 / 匹配方式
度量 : D (定义)
点估计 : D = <值>
不确定度 : 自助法 95% CI [<lo>, <hi>], <n> 次重采样
bootstrap CV: <值> (若 > 0.15, 样本不足)
方向一致性 : <k>/<m> 个配合同向
例外 : <列出反向的配合及其区间>
未声明参数 : <若有>

6.3 两条操作判据

判据一（估计精度）：若某个量的自助法 CV > 0.15，不应据其比较不同语料。

依据：D 的 CV 为 0.012–0.081，而 node_volume 为 0.51–1.91。后者在 n=31 下给出跨 1 的区间 (openqa [0.2709, 1.5824])，**无法支撑结论。**

判据二（效应可分辨）：CV 小不充分，必须同时报告区间是否排除 1。

〔为何需要第二条〕来自一个实测反例 (§2.4 的路线 D)：

	值
方向一致	5/5

跨度	1.01×
区间排除 1	0/5
自助法 CV	0.0026 – 0.0043 (极小)

该量通过了判据一（CV 远小于 0.15），但结论仍不成立——它的效应只有 1%，噪声不足以翻转符号，所以"方向一致"，而 1% 的效应本身与 0 不可分辨。

"方向一致"与"可分辨"是两个判据，必须分别报告。只报前者会产生假阳性；只报后者会掩盖跨域的方向分化。

7. 框架明确不主张的

7.1 不主张"认知沉积量"

D 是语义空间中体积的零参数摘要。它与"认知沉积"的关系是一个解释假设，不是已被证实的事实。

要证实它需要：一个独立定义的"沉积"操作化，以及两者的相关性证据。 本文没有做这件事。

7.2 不主张"人类认知沉积更高"

D 在四个域中人类更低，但（a）一个域反向，（b）为什么低尚未定位（§7.3）。因此不能表述为"人类沉积更低"。

7.3 不主张"人脑 vs LLM"的机制判定

这是本文最重要的限定。

D 给出的是统计可分性；机制判定是另一个命题（P2）。

	统计可分性	机制判定
问题	两组能否被分开？	为什么分开，机制是什么？
D 提供的	✅ 5/5 域可分开	❌ 无
所需	一个判别量	未经筛选的真人独写语料 + 指向生成机制的度量

PACSP-ID §8.5 所设想的判定，本文所有表示都未能回答。这不是本文的失败，而是该类度量（基于嵌入距离）原则上给不出的东西——它们测量的是文本在语义空间中的分布形态，不是生成过程的动力学。

要做那个判定，需要另起一类测量，而不是改进本文的度量。

7.4 不主张"框架已完备"

本文只覆盖：一个参照系、一个表示、一个度量、一套报告规范。 **未覆盖**：时间演化、跨智能体比较、多模态、因果干预。

8. 结论

四条正面结论：

18. **两条原则 (P1 + P1') 可用于筛选度量**：本文以它们淘汰了三种候选表示，改变了第四种的解释，并解释了一个"看起来最好但实际无效"的假阳性 (§1.1、§2.4)。

19. **语料应表示为集合，不是序列**：顺序依赖 20–51%，
且实测**不可通过局部化修复** (§3.3、§3.4)。

20. **'D' 在给定参照系内是最可靠的判别量**：5/5 区间排除 1，精度 1–8%，
且**长度受控后方向保持** (§4.3、§4.4)。 **但它的判别力依赖编码器**：同家族缩小 14 倍参数结论不变，换家族后效应量收缩至不可分辨 (§4.9)。

21. **配对必须同题，且主题不匹配的代价远大于长度不匹配**：

违反主题匹配时比值偏离 **57%** ($0.9205 \rightarrow 1.4426$)，而违反长度匹配时最大偏离 **6.9%**。§4.7 给出完整配对条件。

22. **参照系可分三个层次复用，且集合间比较更精确** (§4.11)：

集合内 (D)、集合间均值 (交叉均值，区间宽度仅 1–2%，**比单个 'D' 精确 1–5 倍**)、集合间可分性 (分离度、重叠占比，跨度 **14 倍**)。

一条重要的界限 (§4.11)：

23. **'D' 回答"组均值是否稳定有序"，不回答"单篇能否归属"**。

五对中只有 lyrics 一对支持单篇可归属 (重叠 0.066)，而 D 比值最极端的 poem 重叠高达 0.797。 **所以不能用 'D' 的比值推断可分性**。

两条否定结论 (同等重要)：

24. **'C_T = \sum \mu_k \delta_k' 不是 'J \mu d \Lambda' 的忠实离散化**，
且顺序敏感是其内禀性质而非缺陷 (§3.4、§5.1)。

25. **三种替代表示都引入了比其所消除者影响更大的未声明参数** (§5)；
各自的复活条件见 §5.5。

一条未解决的：

26. "人脑 vs LLM"的机制判定需要另一类测量，
基于嵌入距离的度量原则上给不出 (§7.3) 。

8.1 落点：本文全部度量测的是**什么**，以及**测不出什么**
这是本文最应当被记住的一段。

本文的所有度量——包括最稳健的 D ——测量的是**文本在嵌入空间中的分布形态**。

分布形态 是生成的产物 (product)
生成动力学 是生成的过程 (process)

因此，无论 D 多么稳健，它原则上不能回答"认知沉积是什么"。它能回答的只是：

在给定的参照系 Ω 中，两组文本的语义分布是否可区分。

但 §4.11 把这句话又收窄了一步，而且这一步更重要：

区分有两个层次。 D 给出的是"组均值的顺序"，不是"单篇的归属"。

D 的 5/5 方向一致容易读成"两组可分"，但 §4.11 显示：

配对	D 比值	重叠占比	单篇可分吗
poem	0.8305 (最极端)	0.797	✗ 否
lyrics	0.8691	0.066	✓ 是

五对中只有一对支持"单篇可归属"。所以更准确的表述是：

D 能回答"两组均值是否稳定地有序"，只在极少数情况下才回答"单篇能否归属"。

这是一个**真实的、有限的、但可复现**的结论。

〔为何把这段放在结论的最后〕

把它划清楚，比扩大它的解释范围更有价值。 D 在 5/5 域中把人类与机器分开，但**"为什么分开"仍未定位**——最需要排除的可能来自 §4.7：若 D 的人机判别实际上是**模板化判别**，则它与"认知沉积"的关系就更远。**五个语料不足以判定**。而 §7.3 已说明：**这类度量给不出机制判定**。

把这一边界写在结论里，是因为它是本文唯一可能被长期引用的东西——不是 D 的数值（那些依赖 Ω ），而是**"基于嵌入距离的度量能回答什么"这一判断**。

测量学论文最稀缺的品质是**边界感**。本文试图提供它，而不是回避它。

附录 A：可复现性

全部数值由本文件夹独立产出，**不依赖任何先前仓库的代码**。

PACSP-M-1.1.0.md	本文
pacsp_core.py	测量核心（6 函数逐字复制自 PACSP-ID 的 pacsp_build.py）
verify_core.py	核心一致性：10/10 冻结值 + 6 函数×3 语料逐位相同
verify_results.py	可复现性：定稿快照 vs 本次运行的 SHA-256
verify_paper_numbers.py	本文数字核验：55 项追溯至 results/
collect_paper_values.py	从 results/ 汇总本文引用的全部数值
data/	21 个语料，1.2 MB
exploration/	28 个脚本
results/	20 个定稿 JSON

已实测的三项验证：

验证	结果
测量核心 vs 流水线（冻结值）	10/10，残差 $\leq 4\times 10^{-5}$
测量核心 vs pacsp_build（实时）	6 函数 × 3 语料 逐位相同
可复现性（SHA-256）	order_sensitivity.json b13f5334067dfc69 一致； n3_mu_localisation.json f40f5ad8d18e36d6 一致
本文数字核验	55/55 项一致

```
cd D:\myproject\PACSP-M
$env:HF_HOME = 'D:\myproject\PACSP-ID\_hf_home' # 模型权重缓存（约 19 GB，未随本文件夹复制）
$env:HF_HUB_OFFLINE = '1'
```

```
python verify_core.py # 先证明测量核心忠实
python verify_paper_numbers.py # 再证明本文数字无误
python collect_paper_values.py # 打印本文引用的全部数值

python exploration\test_order_sensitivity.py # §3.3
python exploration\n3_mu_localisation.py # §3.4
python exploration\f7_intervals.py # §4.3
```

附录 B：本文引用的全部数值及其来源

数值	来源文件
顺序敏感（as-filed/打乱/百分位/CV）	results/order_sensitivity.json
五种 μ 变体的偏差与 CV	results/n3_mu_localisation.json
D 的比值与区间	results/f7_intervals_*.json
C_T 抽样区间	results/ct_tool_demo.json
各度量跨臂跨度	results/e5_baseline_*.json
核嵌入： σ 敏感、帧外误差、图不变性	results/graph_step1_*.json
核嵌入：顺序重排对比	results/functional_test2.json
匹配矩阵图：零模型对照	results/e5c_null_*.json
匹配矩阵图：阈值/词表/短语扫描	results/f1f2_*.json
情绪词数与探针质量	results/f6_mechanism_*.json
自由生成对照、F4 对比	results/f4f6b_*.json
node_volume 区间	results/f1f2_*.json

核验方式：python verify_paper_numbers.py。

附录 C：与 PACSP-ID 7.0.0 的演变关系及过程

C.1 关系定位

PACSP-M 不是 PACSP-ID 的修订版，也不是它的替代品。两者回答不同的问题：

	PACSP-ID 7.0.0	PACSP-M 1.1.0
问题	价值锚定的存在论转向与认知沉积的 理论建构	认知沉积的 可测框架
主要贡献	哲学（意义权）、测度论形式化、六层工程	度量、参照系、效度条件
参照系	隐含于嵌入空间	显式声明 (§2)
表示	序列（路径 γ ）	集合 (§3)
核心量	$C_T = \sum \mu_k \delta_k$ (声称 为沉积总量)	D = 成对距离均值 (不声称 为沉积总量)
敏感性覆盖	1 项（跨嵌入空间）	6 项 (§3.3、§5.1)
未声明参数	窗口、嵌入模型	无 （除已声明的 Ω ）
预印本	DOI 10.5281/zenodo.22801604	本文

保留关系：PACSP-ID 的哲学基底（意义权、海德堡学派）与测度论形式化 **未被本文修改，也未被本文检验**。本文只审查其**工程度量**。

C.2 演变过程（按发现顺序）

起点：PACSP-ID 7.0.0 已如实登记三项负面结果—— S_{int} 不稳健、九个 IDL 指标无一致方向、缺少纯人类对照组。其 §10.6「底层空间敏感性」覆盖跨嵌入偏差（比值 1.43–1.51）。

步	检验	发现	后果
1	顺序敏感（打乱 200 次）	20–51% ，百分位 0.0%	§3.3 的最强单一发现
2	长度与语域	唐代绝句最短却 C_T 最高	记录一次 实际发生的误读
3	句法结构（长度已匹配）	同字数下句数 1.19–1.35×	长度匹配不足够
4	换生成模型	31%	Ω 必须声明 (§2.2)
5	抽样区间	poem 跨 3.54 倍	必须配区间 (§6.1)
6	泛函重构 (Φ, Ψ)	顺序  、 σ  、还原受限	部分否决 (§5.2)
7	图表示 step 1–2	kNN 图置换下 完全不变	顺序敏感的 来源 被定位
8	判别力基线 (E5)	‘D’ 首次出现 ，且优于 C_T	§4 的起点
9	匹配矩阵图	顺序  、 σ  ，但 词表/短语决定性	否决 (§5.3)

10	零模型修正	我曾"完全是伪迹"的表述 过强	自我修正
11	GPU 4-bit 实测	提速 98.6×	使后续扫描可行
12	参数扫描 (F1/F2)	阈值稳、 词表与短语决定性	否决理由确立
13	机理检验 (F6)	探针 不数情绪词 ，但强边来自边缘分布	两处假设被推翻
14	自由生成对照 (F6b)	2/4 域方向相反 ，答案是体裁标签	独立复现短语敏感性
15	决策性对比 (F4)	D 跨度 1.13× vs node_volume 10.95×	否决匹配矩阵图
16	区间估计 (F7)	D 5/5 排除 1 ; node_volume 3/5	§4.3 确立
17	N3 (实现 vs 定义)	不等价，且 局部化不修复	§3.4 确立
18	N4 (σ 的四条路线)	σ  可解，但 四条路线全部丧失判别力 ；其中一条给出 假阳性	§2.4 重写； §6.3 判据被自己的反例修正
19	N6 (H1 主题匹配)	techdoc 的"反向域"是 主题不匹配的产物 ；同题重测后反转消失	§4.5 重写； §4.7 新增配对条件
20	N7 (同质性检验)	"机器文本更同质"的提示被 否定且方向相反 ；差异来自 层级选择	§4.5 未新增； 一处对 §7.1 威胁的排除
21	N8 (三个编码器)	判别力 依赖编码器 ：同家族缩小 14 倍参数不变，换家族后效应量收缩至不可分辨	§4.9 新增 ；"零参数"须限定为"相对于给定 Ω "
22	N9 (集合间关系)	参照系 可分三层次复用 ，集合间比较更精确；但 D 不回答案篇归属	§4.11 新增 ；解释边界再收窄一步

c.3 九处关键修正

本文的九项主张是在**推翻自己**之后形成的：

初始假设	实测	影响
μ_k 局部化能降低顺序敏感	 反而升高 (0.1915 $\rightarrow$ 0.2457)	促成 §3.4 与集合表示
保边缘的秩 1 重构可解释全部层级边	 只解释 39.6–83.4%	修正过强表述
阈值 t 主导匹配矩阵图结构	 20 倍变化只引起 1–22%	修正归因
残差修正消除秩 1 伪迹	 破坏方向一致性	否决该方案
「自助法 cv 小 估计可靠」	 cv 小只说明精确，不说明效应非零	§6.3 增加第二条判据
「`techdoc` 是方向相反的域」	 该配对同域而不同题；同题后反转消失	§4.5 重写； §4.7 新增配对条件
「机器文本更同质」	 方向相反：机器文本离散度更大	§4.5 未新增；排除一个对 §7.1 的威胁

「D 是零参数的」	✗ 仅相对于给定 Ω ；判别力依赖编码器	§4.9 新增；"零参数"被限定
「D 的 5/5 方向一致说明两组可分」	✗ D 比较组均值，不回答单篇归属	§4.11 新增；五对中仅一对支持单篇可归属

第五处修正的细节（值得单独记录）

它来自 σ 路线 D 的假阳性：

路线 D 的表现	值
方向一致	5/5
跨度	1.01×
自助法 CV	0.0026 – 0.0043（远小于 §6.3 的 0.15 阈值）
区间排除 1	0/5

它通过了 §6.3 原本唯一的判据，但结论仍不成立——效应只有 1%，噪声不足以翻转符号，所以"方向一致"；而 1% 的效应本身与 0 不可分辨。

"方向一致"与"可分辨"是两个判据。只报前者产生假阳性；只报后者掩盖跨域方向分化。两条必须都在。

〔为何这一处特别值得记录〕前四处修正是发现某个方案不行；这一处是发现自己的检验规则不充分——它只在遇到一个"看起来最成功"的候选时才暴露。

第六处修正的细节

它来自对 techdoc 那一格的重新审计：

阶段	比值	判定
原配对（同域但不同题，长度差 7.92×	1.4426	反转
同题重测（在同题上生成机器臂）	0.9205	反转消失
+ 去重（剔除重复文本）	1.4313	反转仍在（排除了重复文本的解释）
+ 长度控制（裁至共同中位长度）	0.9210	变化 0.1%

这一步发现的是配对错误，不是度量错误。

〔为何这一处与前五处不同〕前五处都在检验度量或规则；这一处检验的是数据配对本身。它揭示了一个容易漏掉的事实：

"同域"不等于"问题"。人类臂写数字货币、机器臂写 Python 环境，两者同属"技术文档"域，但比较的是主题差异。

而主题不匹配的代价（57%）远大于长度不匹配（6.9%）——后者是显见的混淆，前者是隐性的。

第七处修正的细节

它来自对同一提示的检验，而**结论与提示相反**：

层面	人类	机器	判定
臂级 D（5 vs 5 个点）	跨度 2.06×	跨度 1.83×	曾疑"机器更同质"
单篇离质心距离（平均，155 vs 155）	—	—	无差别（区间含 1，5/5 预算）
单篇距离的离散度	更小	更大（2.2–4.7×	方向与提示相反

人类臂内的篇目彼此更相似，且相似程度更均匀；机器臂的平均相似度与人类相同，但内部差异更大。

〔为何这一处与前六处不同〕前六处修正都始于**对方案的怀疑**；这一处始于一个**我们主动记下的提示**，而检验表明该提示是**层级选错的产物**：臂级比较只有 10 个点，降到单篇层面后信号方向反转。

第八处修正的细节

它来自一个外部质疑：**结论是否因为所用模型太小**。三个编码器实测：

编码器	维度	家族	方向一致	跨度
ge-large-zh-v1.5	1024	bge	5/5	1.13×
ge-small-zh-v1.5	512	bge	5/5	1.12×
ext2vec-base-chinese	768	其他	3/5	1.22×

参数缩小 14 倍（326M → 24M）结论不变；换家族后部分失效。跨家族的平均绝对差是同家族的 1.88 倍。

〔但失效的性质不是反转〕 ext2vec 的两处不一致是 1.0100 与 1.0048，即比 1 高 1.0% 与 0.5%。**那不是方向反转，是效应量收缩到 1 附近、变得不可分辨**。它的平均 |比值-1| 只有 0.0496，是三者中最低的。

在 text2vec 空间中，人机差异总体更小，两处配对收缩到 1 附近，于是方向一致这个判据失去分辨力。

〔为何这一处最重要〕它修正的不是某个方案，而是**本文对 D 的核心表述**："零参数"必须被限定为"**相对于给定参照系 Ω** "，因为编码器本身就是 Ω 里的一个参数，而判别力依赖它。**这直接影响 §4.3 结论的强度，并触发 P1' 的复核要求**。

第九处修正的细节

它来自一个超出本文原定用法的问题：**参照系能否标定多个集合之间的关系**。

答案是可以，而且分三个层次。但回答它的过程中发现了一处**本文先前的过度解读**：

配对	D 比值	重叠占比	单篇可分吗
poem	0.8305（最极端）	0.797	✗ 否
lyrics	0.8691	0.066	✓ 是

D 比值最极端的那一对，两组分布大量交错；D 比值不是最极端的那一对，两组几乎分离。

D 比较的是组均值，重叠占比问的是单篇归属。这是两个不同的问题。五对中只有一对支持"单篇可归属"。

〔为何这一处重要〕前八处修正针对的是**某个方案、某条规则、某对数据、某个参数**；这一处针对的是**本文对自身结果的解读**——D 的 5/5 方向一致容易读成"两组可分"，而**数据不支持这个读法**。

它降低了过度解读的风险，方向是有利的。

记录这些，是因为"如何发现自己是错的"比结果本身更可复用 (§1.1)。

C.4 未变的部分

项	状态
意义权、海德堡学派、匿名前反思自身意识	未修改、未检验
压抑势能定律	未修改、未检验
六层密码学防护 (L1–L6)	未修改；全新克隆 8/8 记录复现通过
勒贝格分解形式化	未修改； $\int \mu \, d\Lambda$ 的定义正确，问题在于把它等同于 $\sum \mu_k \delta_k$
四类篡改攻击检测	未修改；全部捕获

C.5 对 PACSP-ID 的具体建议

#	位置	现状	建议
1	§10.2 三域认知沉积量	只给点估计 (1.9 / 2.1 / 7.4)	补区间；techdoc 一格的 配对须同题重建 (§4.5、§4.7)
2	§3.5 / §9.2	视为 $\int \mu \, d\Lambda$ 的实现	声明 不等价 (§3.4)
3	§5.3 结构差异	「 μ_k 随认知负荷严格递增」	限定 同域、长度受控 (§4.4)
4	§8.5 判定表	声称可判别	降为 待验证 (§7.3)
5	§10.6 底层空间敏感性	1 项	补足 6 项 (§3.3、§5.1)
6	新增	—	报告 D 作为稳健对照量 (§4)
7	§6.1 测量有效性的存在论条件	哲学论述	实质化为报告规范 (§6)
8	新增 (本次修订)	配对未声明主题来源	报告配对的主题来源 ；主题不匹配时明确标注 (§4.7)

〔第 8 条为何重要〕这是本次修订**新发现**的一类错误。原 §10.2 的三个域中，techdoc 一格的机器臂与人类臂**同域而不同题**，使该格比较的是主题差异（偏离 57%），不是人机差异 (§4.5)。**主题不匹配的代价远大于长度不匹配** (57% vs 6.9%)，而后者是显见的、前者是隐性的。

C.6 一个诚实的总结

PACSP-ID 7.0.0 的哲学与数学部分经得起本次审查；其工程度量的解释经不起。

本文不是"PACSP-ID 更好了", 而是"**其中一部分被证明可用, 另一部分不是**". 这个区分是本文唯一的贡献, 而它是靠**正面比较**得出的, 不是靠论证。

参考文献

本文直接依据

- Chung, F., & Lu, L. (2002). The average distances in random graphs with given expected degrees. *PNAS*, 99(25), 15879–15882.
- Killick, R., Fearnhead, P., & Eckley, I. A. (2012). Optimal detection of changepoints with a linear computational cost. *JASA*, 107(500), 1590–1598.
- Lyons, T. (1998). Differential equations driven by rough signals. *Revista Matemática Iberoamericana*, 14(2), 215–310.

演变来源

- PACSP-ID 7.0.0 (docs/PACSP-ID-7.0.0-COMPLETE.md) ,
预印本 DOI 10.5281/zenodo.22801604, 版本 DOI 10.5281/zenodo.23138930。

PACSP-ID 内部文献表 (哲学、认知科学、密码学) 见其 §参考文献, 本文未重复。